第9章 虚拟内存: 系统

教　师：　郑贵滨
计算机科学与技术学院
哈尔滨工业大学

主要内容

- 一个小内存系统示例
- 案例研究: Core i7/Linux 内存系统
- 内存映射

符号回顾Review of Symbols

- 基本参数
  - **N = 2^n :虚拟地址空间中的地址数量**
  - **M = 2m : 物理地址空间中的地址数量**
  - **P = 2^p ：页的大小 (bytes)**
- 虚拟地址组成部分
  - **TLBI: TLB(组)索引**
  - **TLBT: TLB 标记**
  - **VPO: 虚拟页面偏移量（字节）**
  - **VPN: 虚拟页号**
- 物理地址组成部分
  - **PPO:物理页面偏移量 (same as VPO)**
  - **PPN:物理页号**
  - **CO: 缓冲块内的字节偏移量**
  - **CI: Cache 索引**
  - **CT: Cache 标记**

一个小内存系统示例

- 地址假设
  - 14位虚拟地址（n=14）
  - 12位物理地址（m = 12）
  - 页面大小64字节（P = 64）

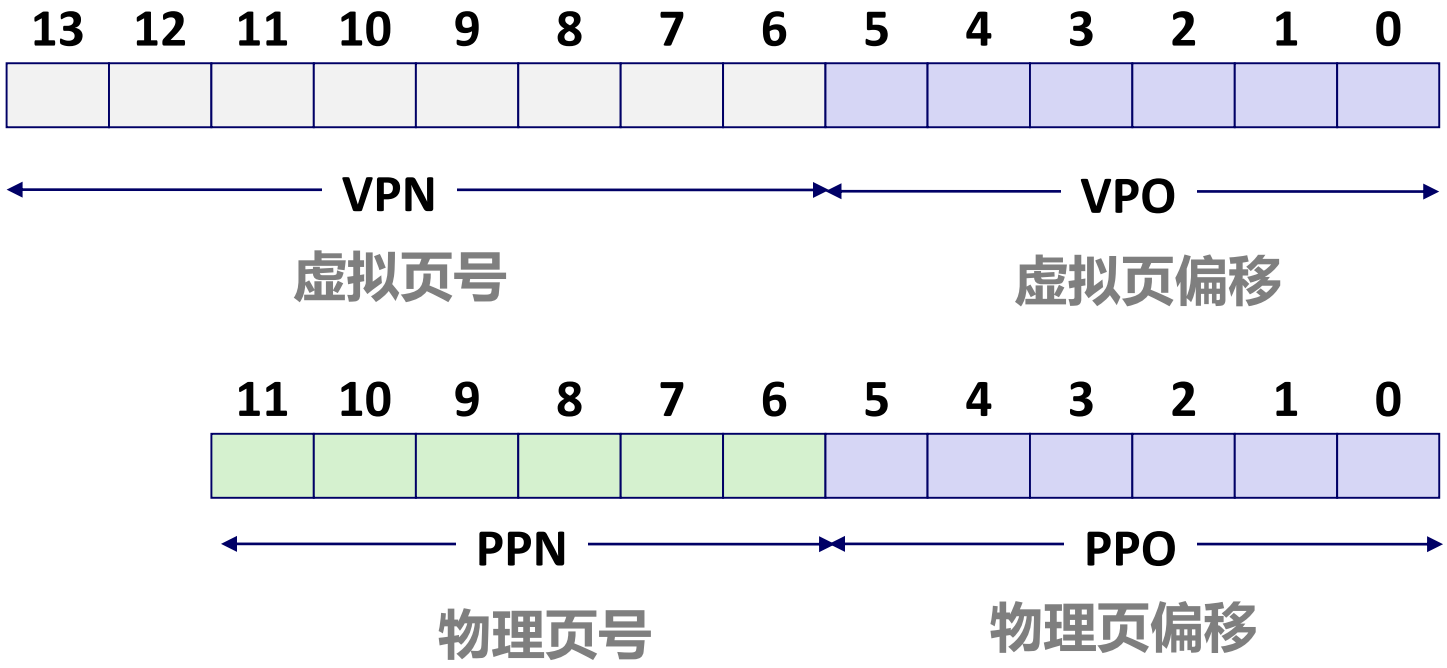

1. 小内存系统的 TLB

- 16个条目(16 entries)
- 4路组相联(4-way associative)
  - 4组，组索引2位

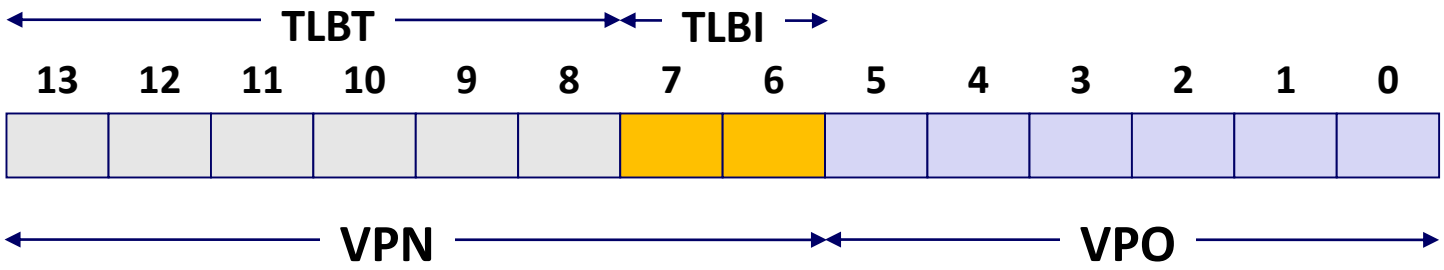

组Set	Tag	PPN	Valid	Tag	PPN	Valid	Tag	PPN	Valid	Tag	PPN	Valid
0	03	–	0	09	0D	1	00	–	0	07	02	1
1	03	2D	1	02	–	0	04	–	0	0A	–	0
2	02	–	0	08	–	0	06	–	0	03	–	0
3	07	–	0	03	0D	1	0A	34	1	02	–	0

2. 小内存系统的页表

- 256个PTE中的前16个PTE：

VPN	PPN	Valid
00	28	1
01	–	0
02	33	1
03	02	1
04	–	0
05	16	1
06	–	0
07	–	0

VPN	PPN	Valid
08	13	1
09	17	1
0A	09	1
0B	–	0
0C	–	0
0D	2D	1
0E	11	1
0F	0D	1

3. 小内存系统的 Cache

- 共64字节:直接映射(每组一行),16个组,每块/行4字节
- 用物理地址寻址

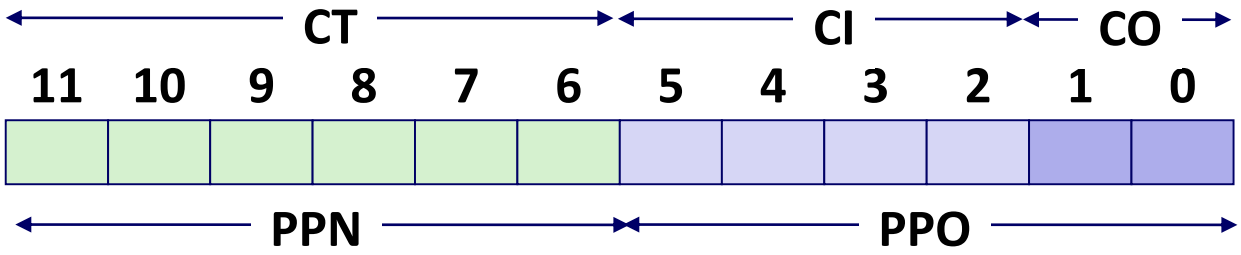

Idx	Tag	Valid	B0	B1	B2	B3
0	19	1	99	11	23	11
1	15	0	–	–	–	–
2	1B	1	00	02	04	08
3	36	0	–	–	–	–
4	32	1	43	6D	8F	09
5	0D	1	36	72	F0	1D
6	31	0	–	–	–	–
7	16	1	11	C2	DF	03

Idx	Tag	Valid	B0	B1	B2	B3
8	24	1	3A	00	51	89
9	2D	0	–	–	–	–
A	2D	1	93	15	DA	3B
B	0B	0	–	–	–	–
C	12	0	–	–	–	–
D	16	1	04	96	34	15
E	13	1	83	77	1B	D3
F	14	0	–	–	–	–

地址翻译 Example #1

虚拟地址: 0x03D4，读取1字节数据

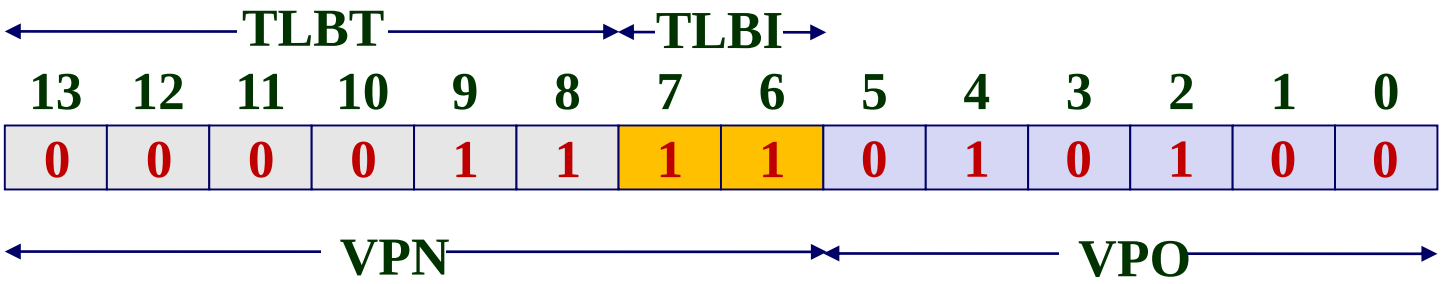

VPN 0x0F TLBI 0x3 TLBT 0x03 TLB Hit? Y Page Fault? N PPN: 0x0D

物理地址

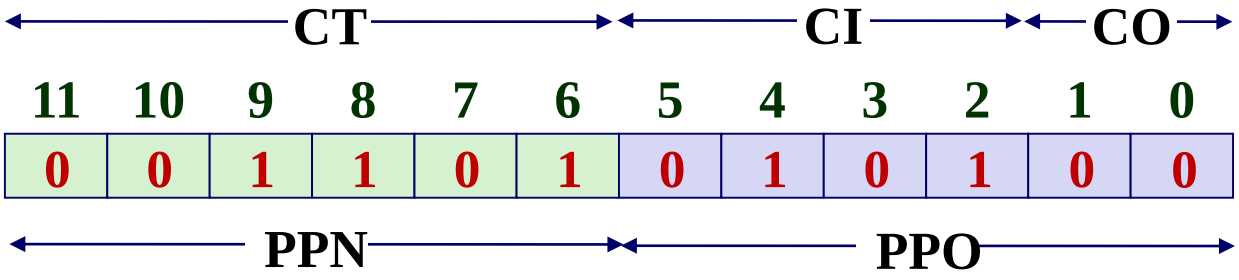

CO 0 CI 0x5 CT 0x0D Hit? Y Byte: 0x36

地址翻译 Example #2

虚拟地址: 0x0020， 读取1字节数据

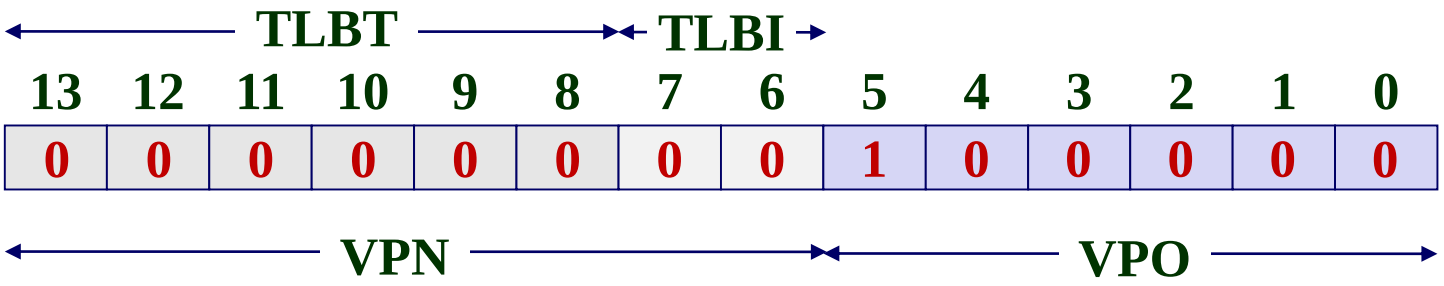

VPN 0x00 TLBI 0 TLBT 0x00 TLB Hit? N Page Fault? N PPN: 0x28

物理地址

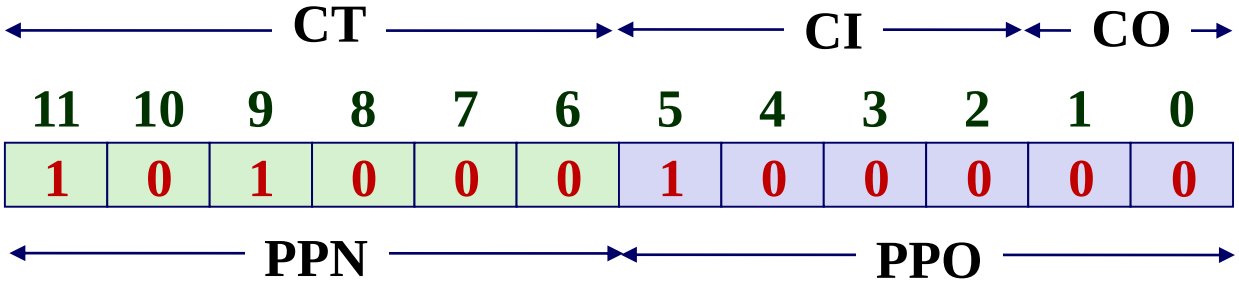

CO 0 CI 0x8 CT 0x28 Hit? N Byte: Mem

主要内容

- 一个小内存系统示例
- 案例研究: Core i7/Linux 内存系统
- 内存映射

符号回顾Review of Symbols

- 基本参数
  - **N = 2^n :虚拟地址空间中的地址数量**
  - **M = 2m : 物理地址空间中的地址数量**
  - **P = 2^p ：页的大小 (bytes)**
- 虚拟地址组成部分
  - **TLBI: TLB(组)索引**
  - **TLBT: TLB 标记**
  - **VPO: 虚拟页面偏移量（字节）**
  - **VPN: 虚拟页号**
- 物理地址组成部分
  - **PPO:物理页面偏移量 (same as VPO)**
  - **PPN:物理页号**
  - **CO: 缓冲块内的字节偏移量**
  - **CI: Cache 索引**
  - **CT: Cache 标记**

Intel Core i7 内存系统

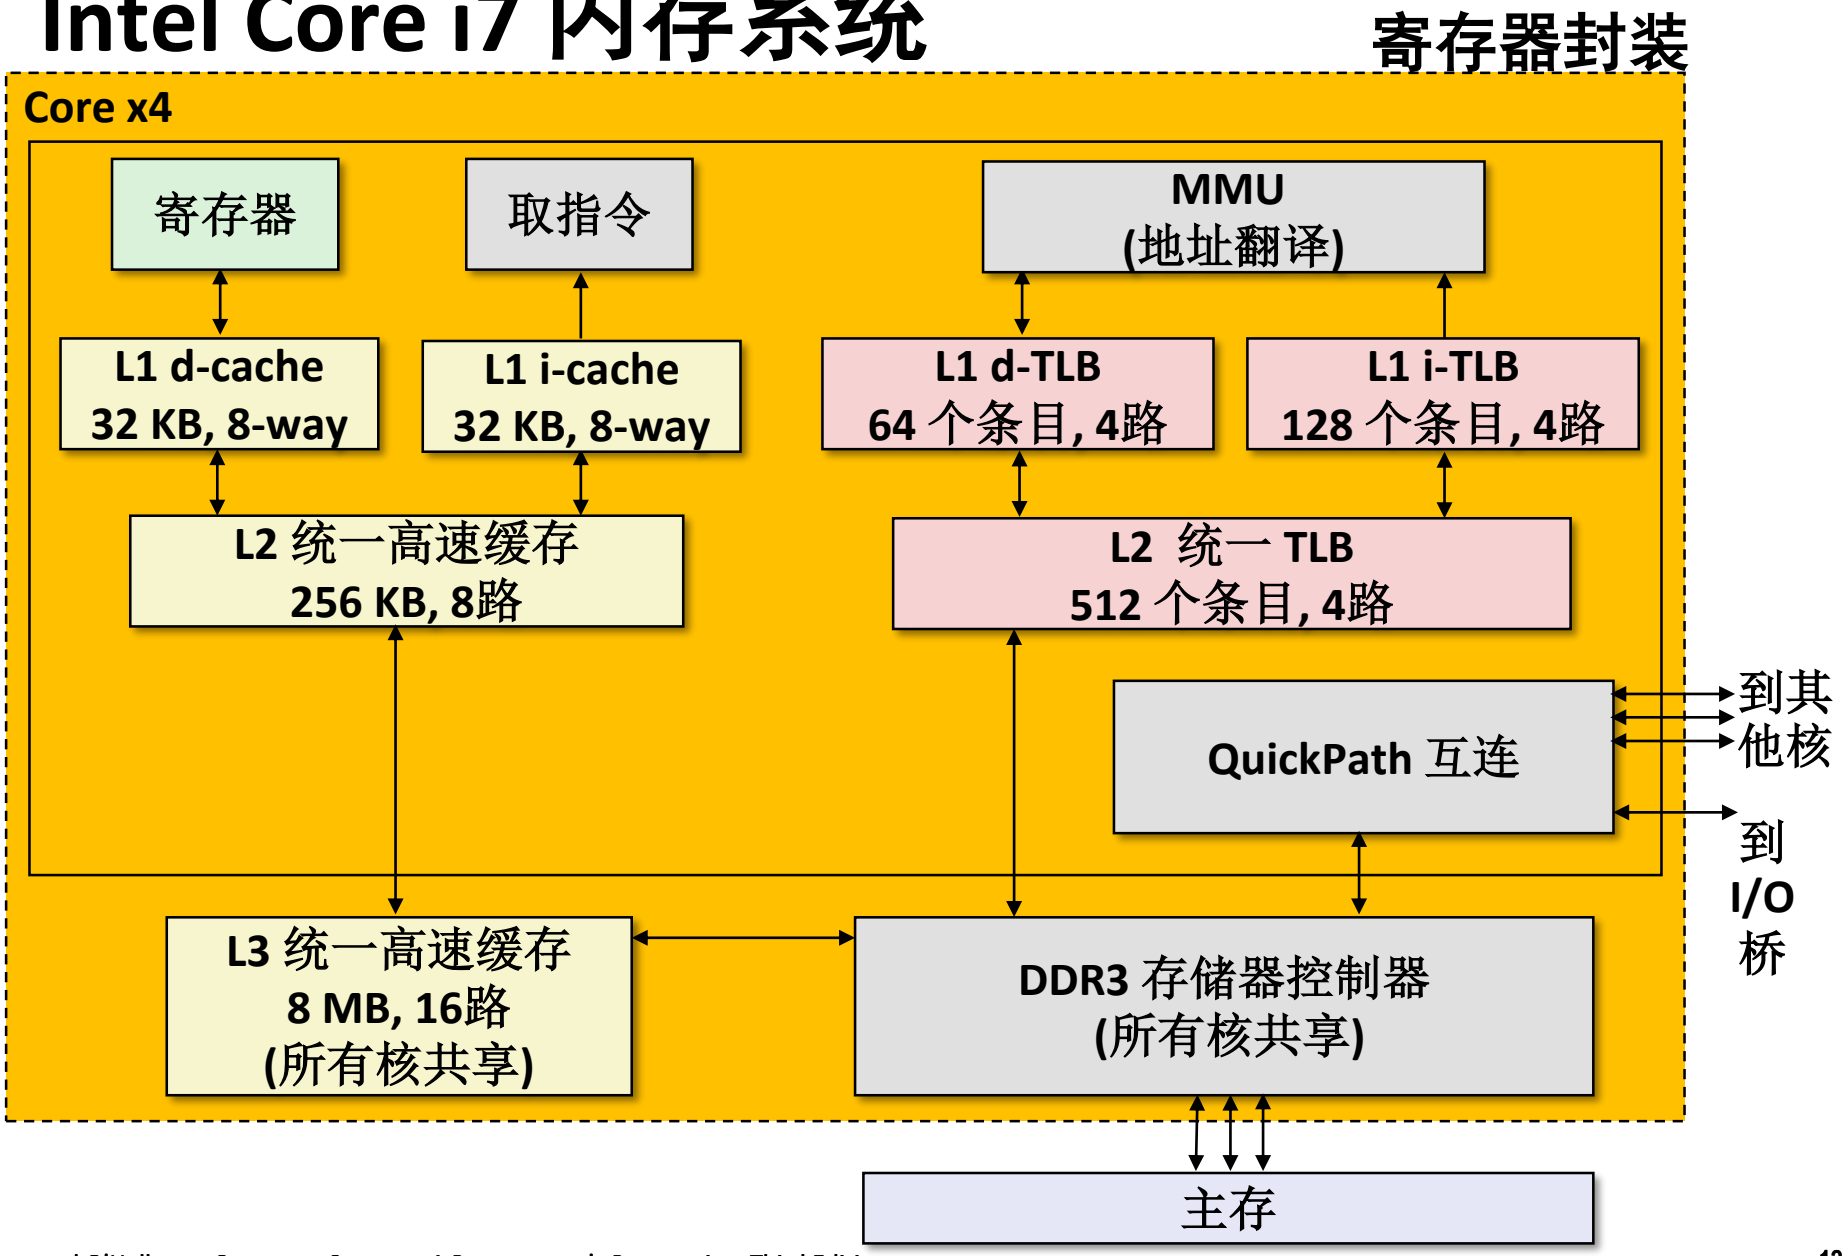

Core i7 地址翻译

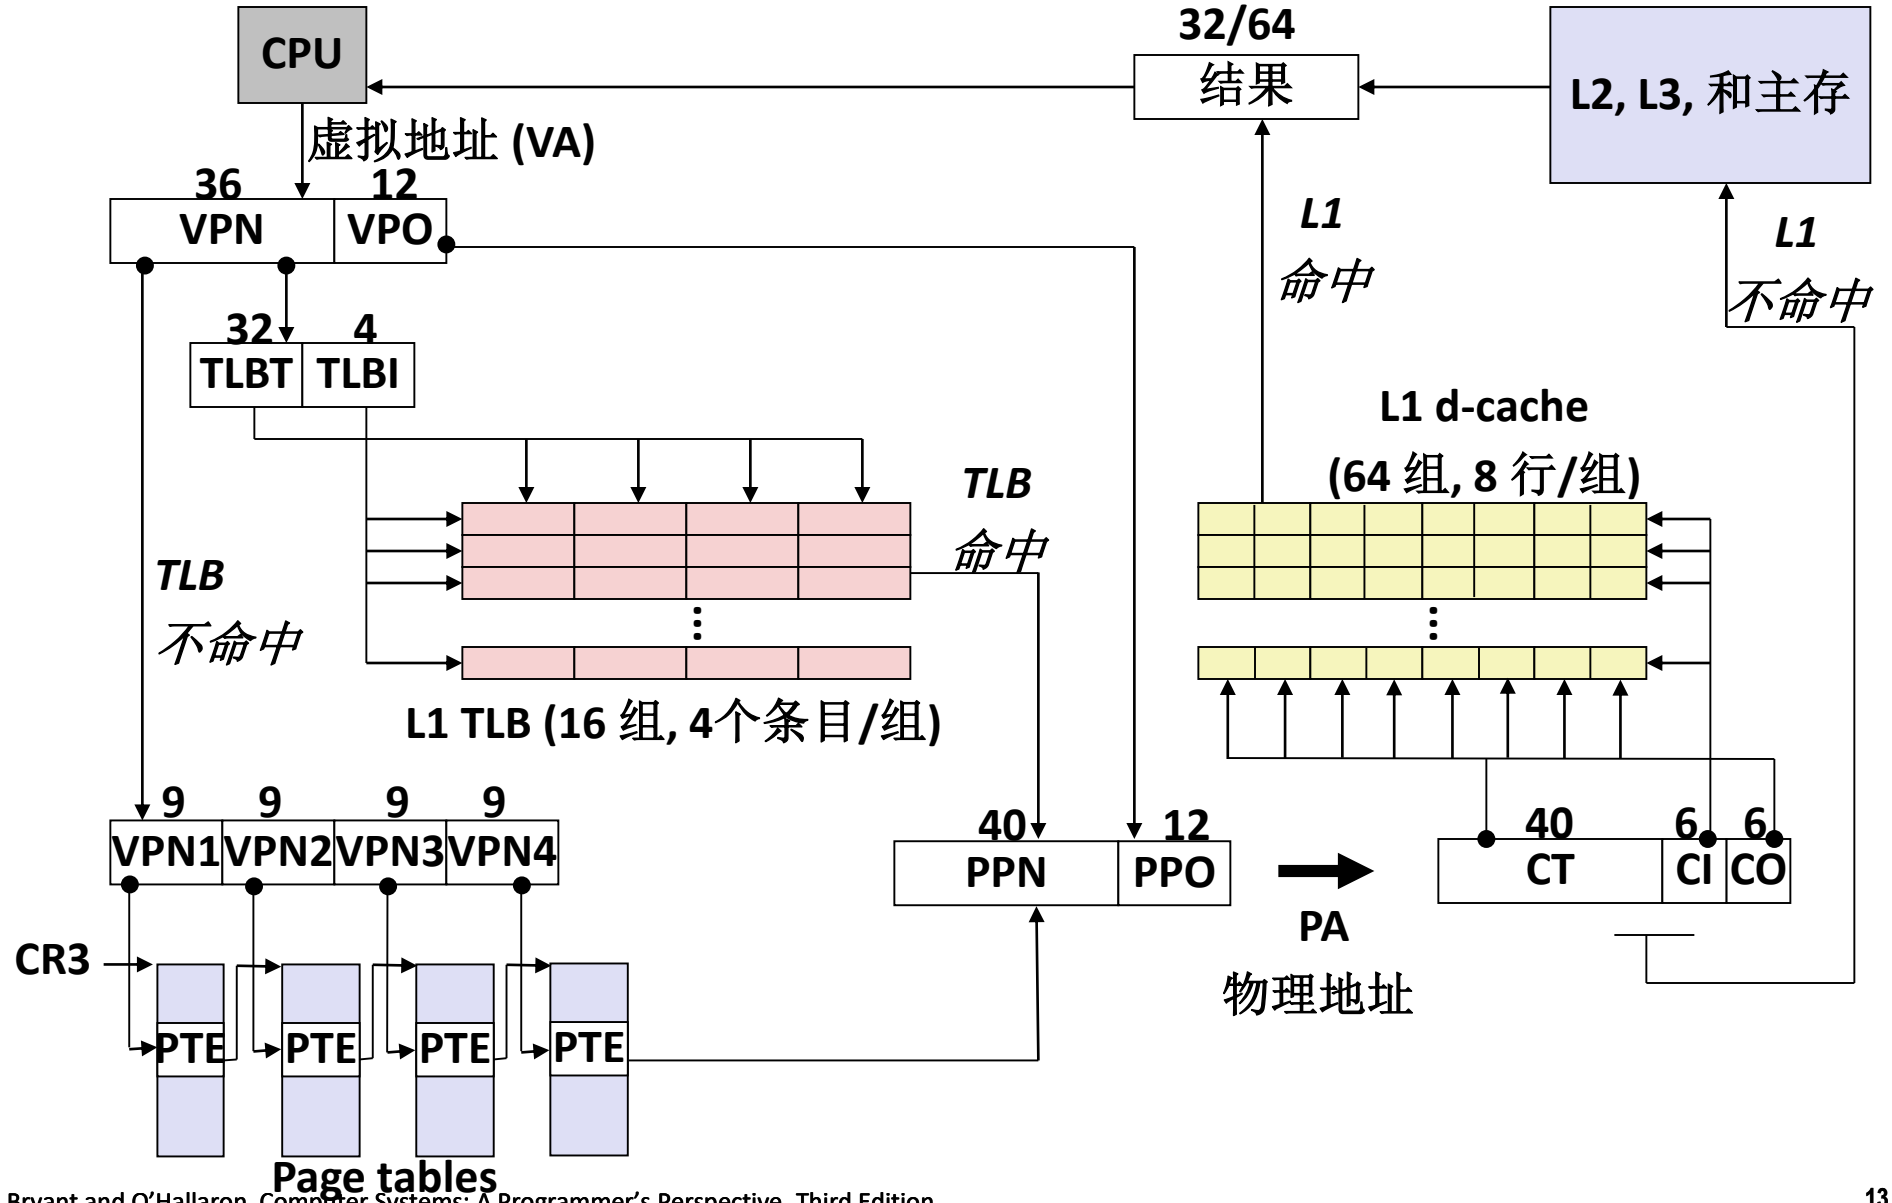
CPU
32/64
结果
L2, L3, 和主存
虚拟地址 (VA)
36
12
VPN
VPO
L1
命中
L1
不命中
32
4
TLBT
TLBI
L1 d-cache
(64 组, 8 行/组)
TLB
命中
TLB
不命中
L1 TLB (16 组, 4个条目/组)
9
9
9
9
VPN1
VPN2
VPN3
VPN4
40
12
PPN
PPO
40
6
6
CT
CI
CO
PA
物理地址
CR3
PTE
PTE
PTE
PTE
Page tables

教材p578

Core i7 1-3级页表条目格式

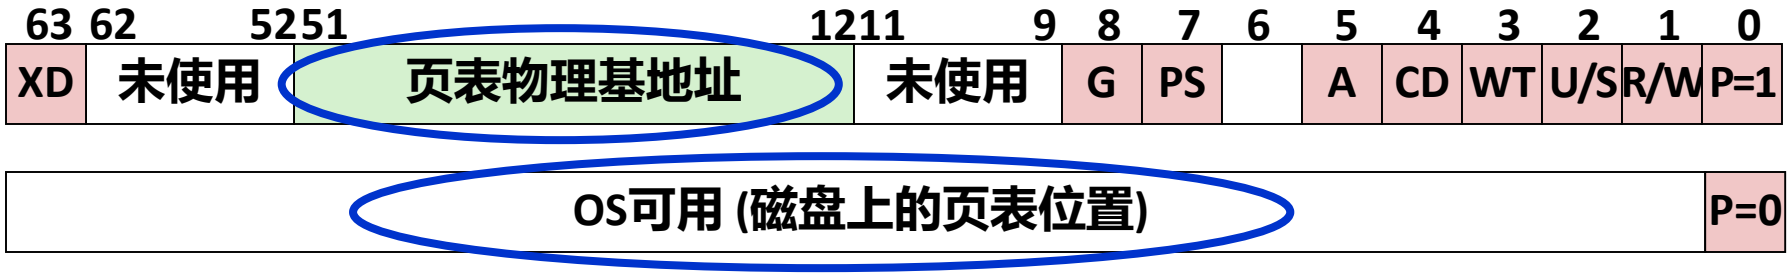

每个条目引用一个 4KB子页表:

P: 子页表在物理内存中 (1)不在 (0)

R/W: 对于所有可访问页，只读或者读写访问权限

U/S: 对于所有可访问页，用户user或超级用户supervisor(内核)模式访问权限

WT: 子页表的直写或写回缓存策略

A: 引用位 (由MMU 在写时设置，由软件清除)

PS: 页大小为4 KB 或 4 MB (只对第一层PTE定义)

页表物理基地址: 子页表物理基地址的最高40位 (强制物理页表 4KB 对齐)

XD: 能/不能从这个PTE可访问的所有页中取指令

教材p578

Core i7 第 4 级页表条目格式

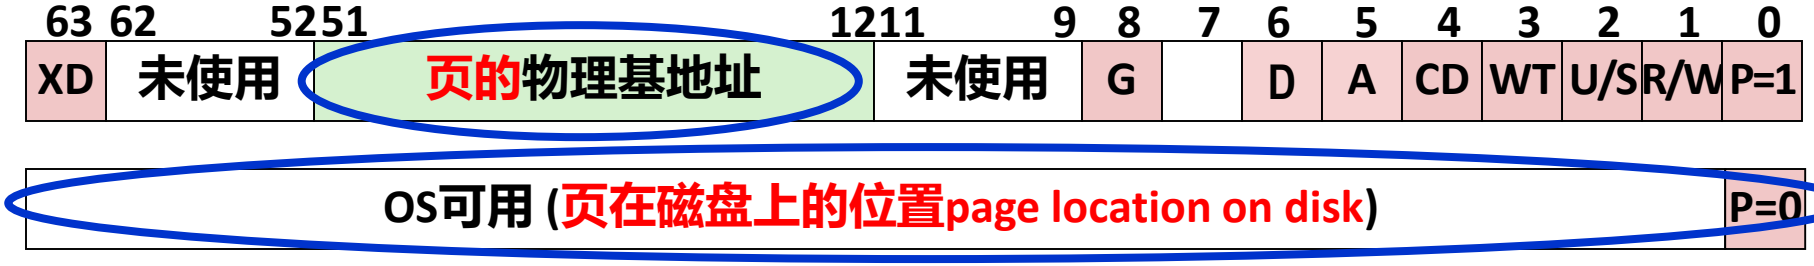

每个条目引用一个4KB的页:

P: 子页表在物理内存中 (1)不在 (0)

R/W: 对于所有可访问页，只读或者读写访问权限

U/S: 对于所有可访问页，用户或超级用户 (内核)模式访问权限

WT: 子页表的直写或写回缓存策略

SD：能/不能缓存(Cache disabled or enabled)

A: 引用位 (由MMU 在读或写时设置，由软件清除)

D: 修改位(Dirty bit, 由MMU 在写时设置，由软件清除)

页表物理基地址: 物理页基地址的最高40位(强制物理页 4KB 对齐)

XD: 能/不能从这个PTE可访问的所有页中取指令

Core i7 页表翻译

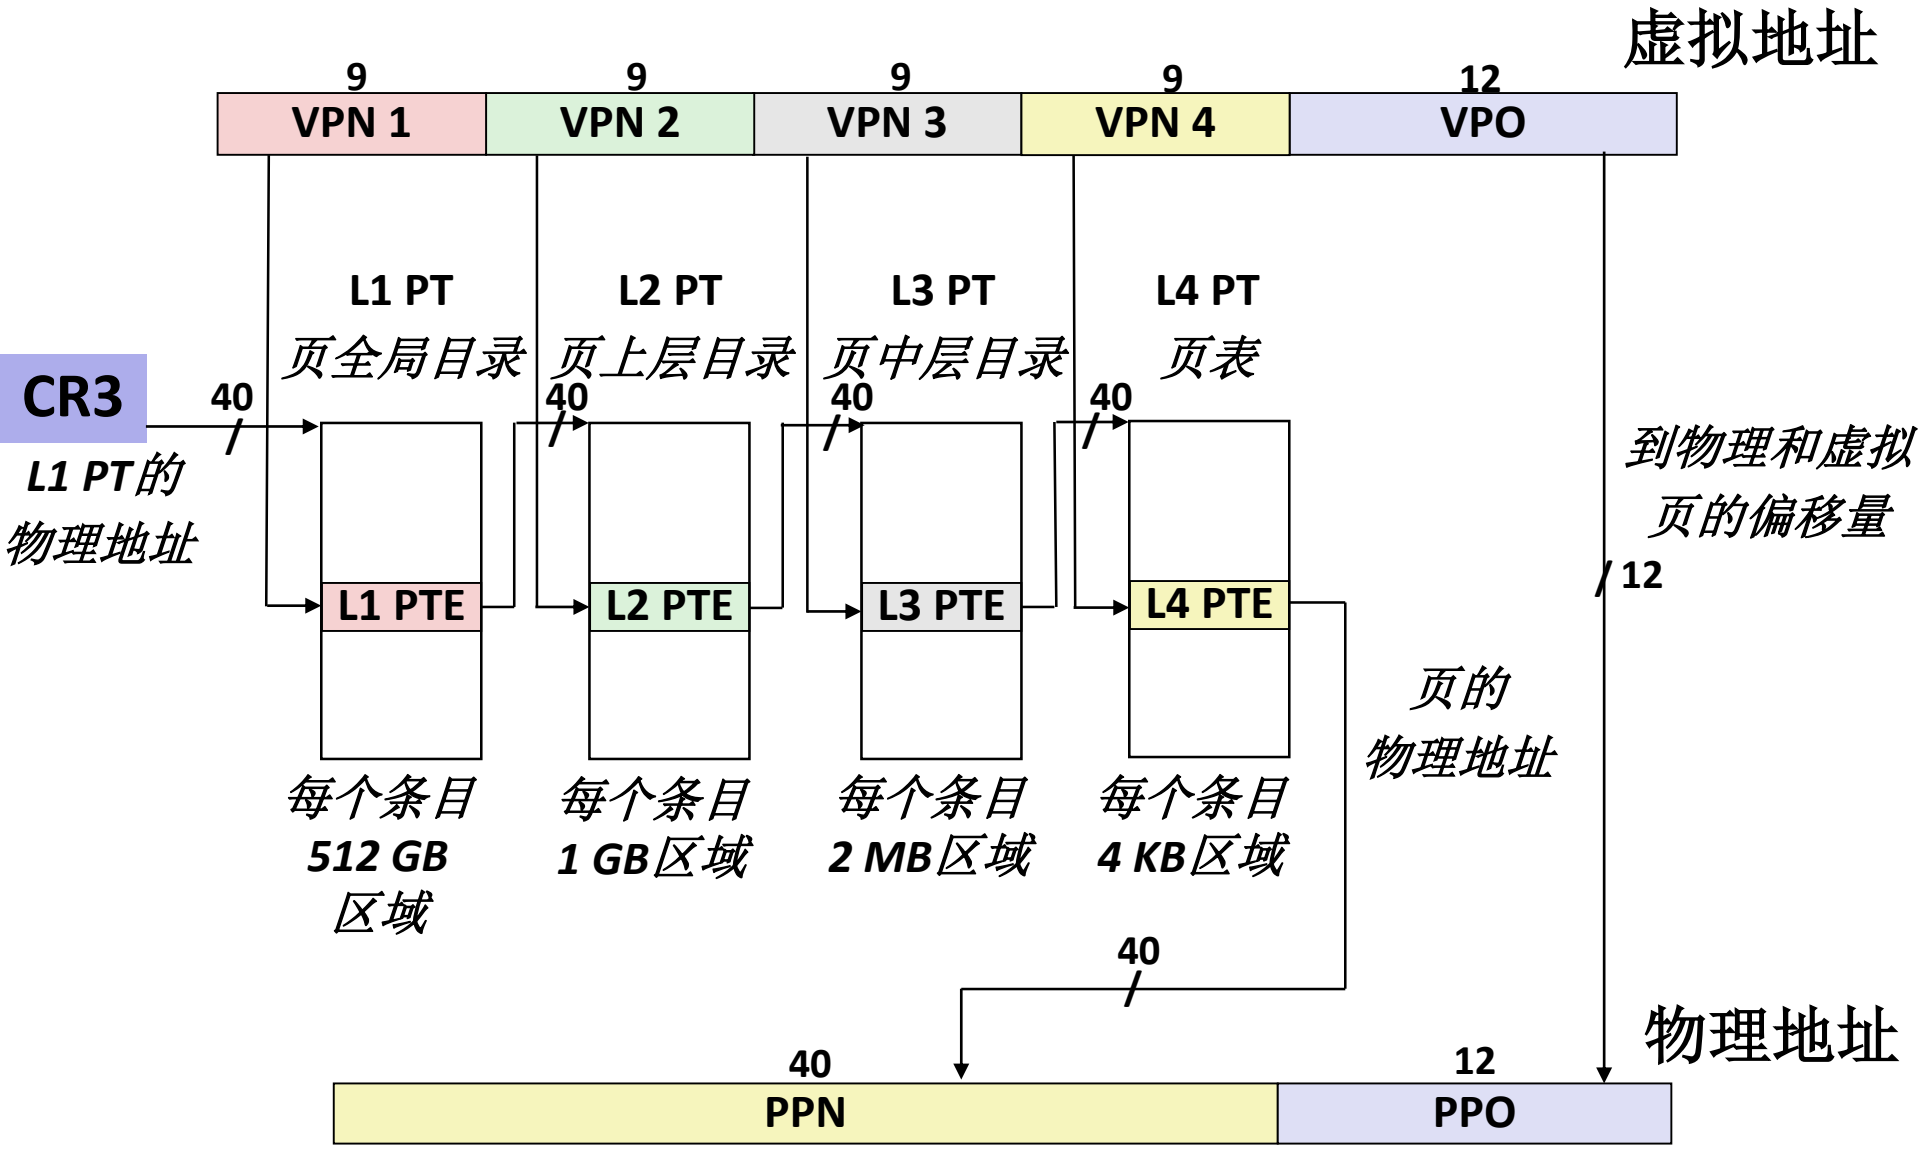
虚拟地址
9
9
9
9
12
VPN 1
VPN 2
VPN 3
VPN 4
VPO
L1 PT
页全局目录
L2 PT
页上层目录
L3 PT
页中层目录
L4 PT
页表
CR3
L1 PT的
物理地址
40
40
40
40
L1 PTE
L2 PTE
L3 PTE
L4 PTE
每个条目
512 GB
区域
每个条目
1 GB区域
每个条目
2 MB区域
每个条目
4 KB区域
到物理和虚拟
页的偏移量
12
页的
物理地址
40
物理地址
40
12
PPN
PPO

一个Linux 进程的虚拟地址空间

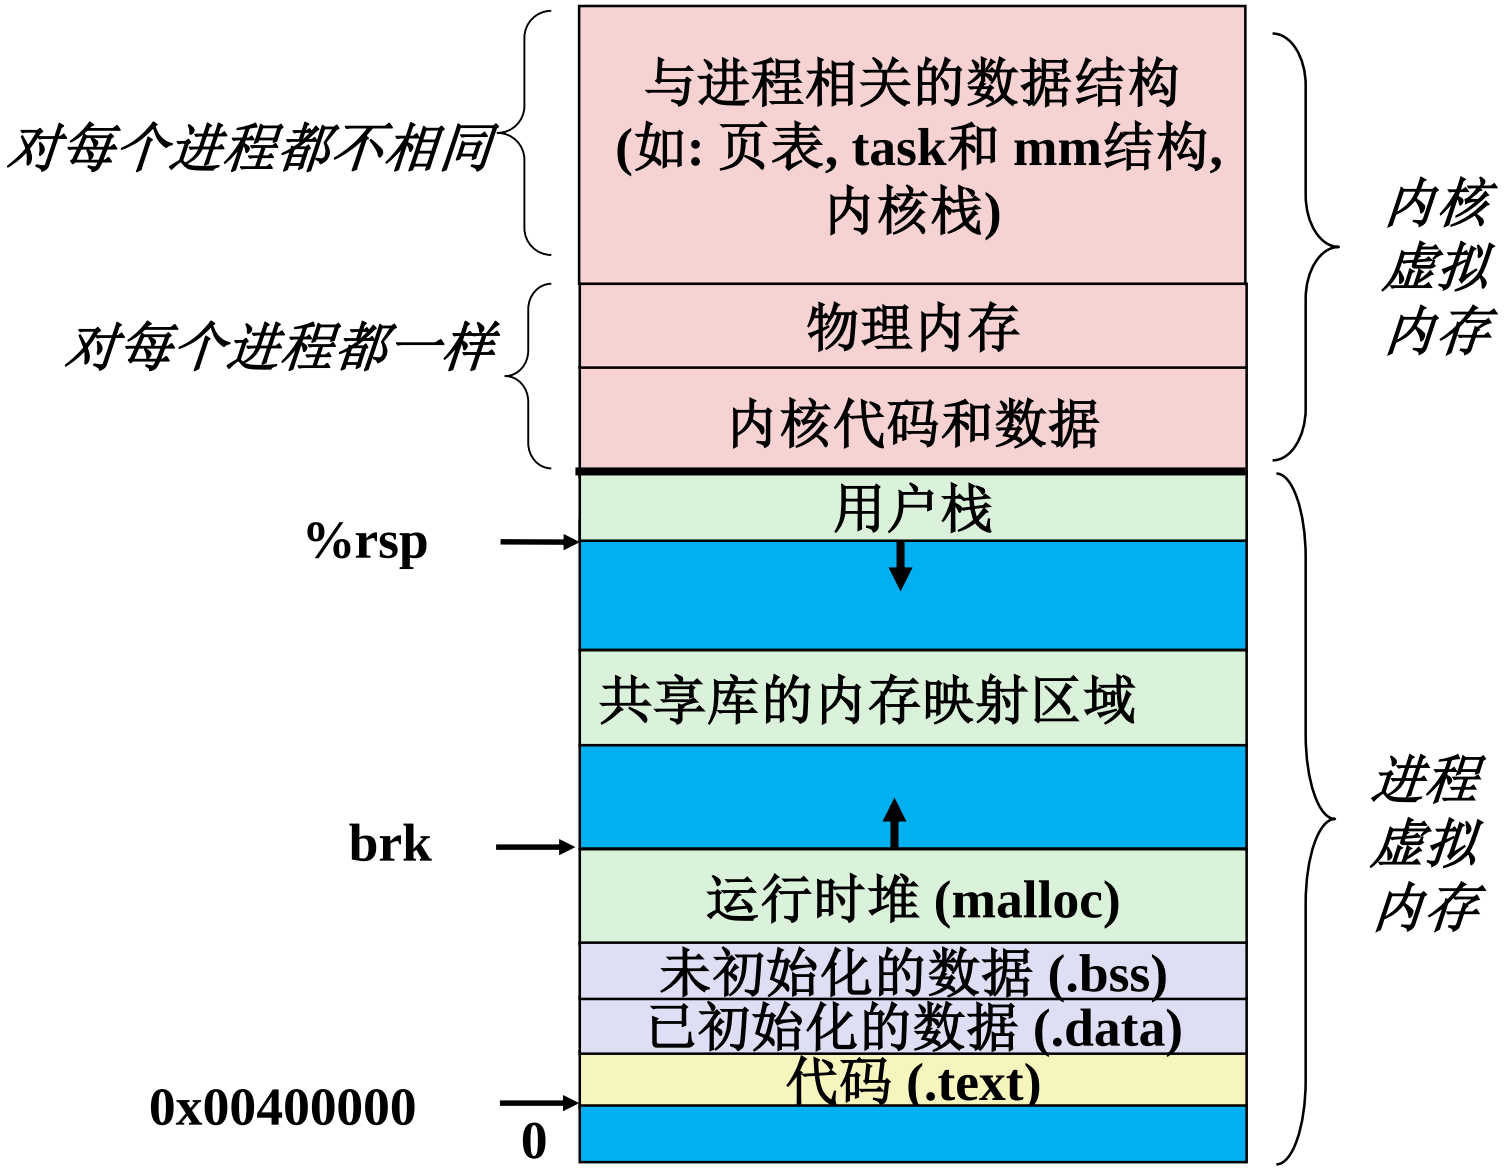

Linux将虚拟内存组织成一些区域的集合

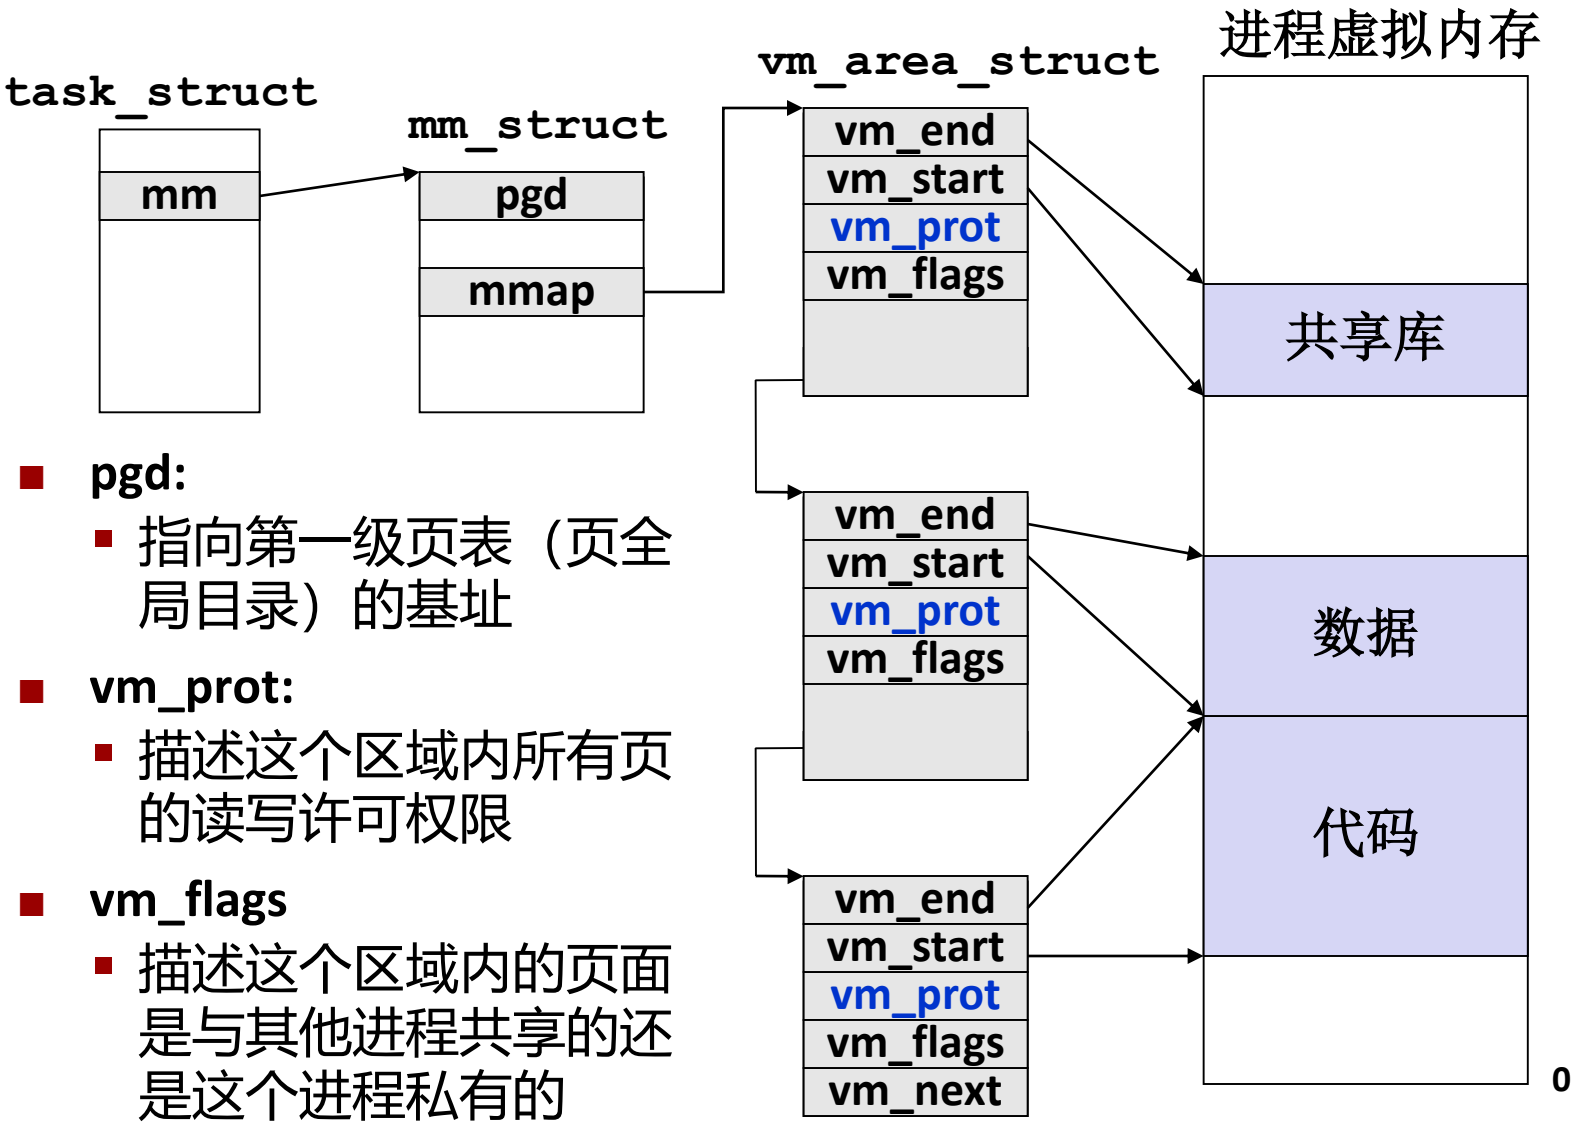

- pgd:
  - 指向第一级页表（页全局目录）的基址
- vm_prot:
  - 描述这个区域内所有页的读写许可权限
- vm_flags
  - 描述这个区域内的页面是与其他进程共享的还是这个进程私有的

Linux缺页处理

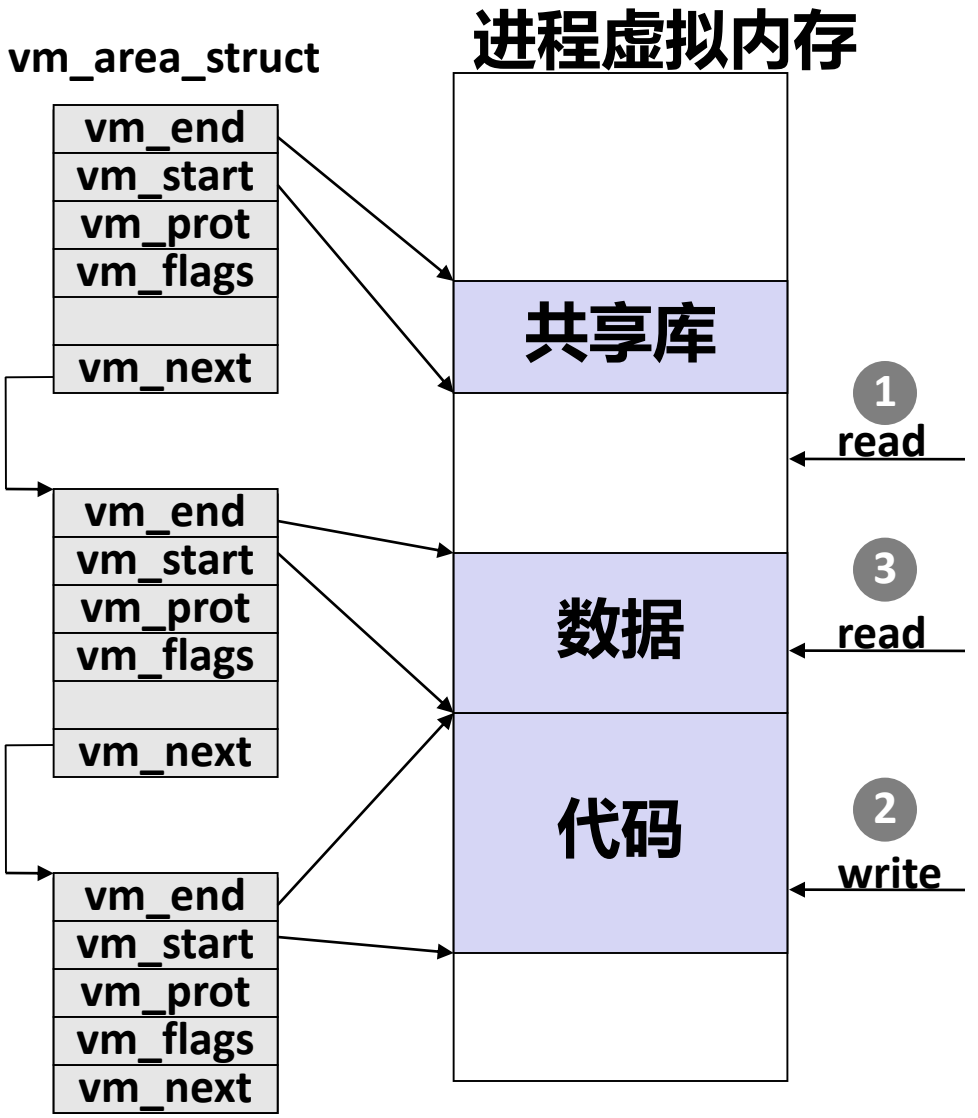

段错误:
访问一个不存在的页面，缺页处理程序搜索区域链表，检查是否合法？→非法

正常缺页

保护异常:
例如：违反许可，写一个只读的页面(Linux 报告 Segmentation fault)

主要内容

- 一个小内存系统示例
- 案例研究: Core i7/Linux 内存系统
- 内存映射

内存映射

- Linux通过将虚拟内存区域与磁盘上的对象关联起来以初始化这个虚拟内存区域的内容.
  - 这个过程称为内存映射（***memory mapping***）.
- 虚拟内存区域可以映射的对象 (根据初始值的不同来源分) :
  - **磁盘上的*普通文件*** (e.g.,一个可执行目标文件)
    - 文件区被分成页大小的片，对虚拟页面初始化
  - ***匿名文件*** (内核创建，全是二进制零)
    - 首次访问该区域的虚拟页会引发缺页异常→分配一个全零的物理页 (***demand-zero page请求二进制零的页***)
    - 一旦该页面被修改，即和其他页面一样
- 初始化后的页面在内存和交换文件（ *swap file*）之间换来换去

再看共享对象

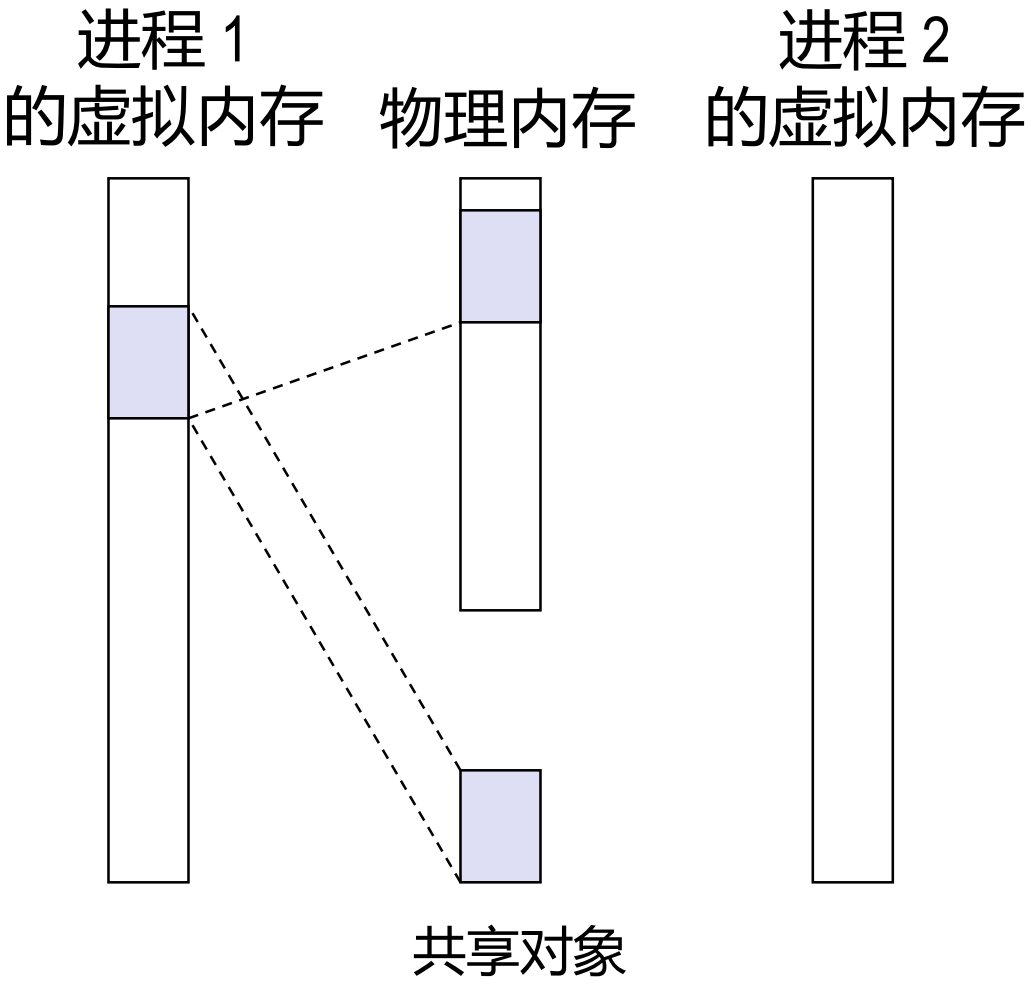

- 进程 1 映射了共享对象

再看共享对象

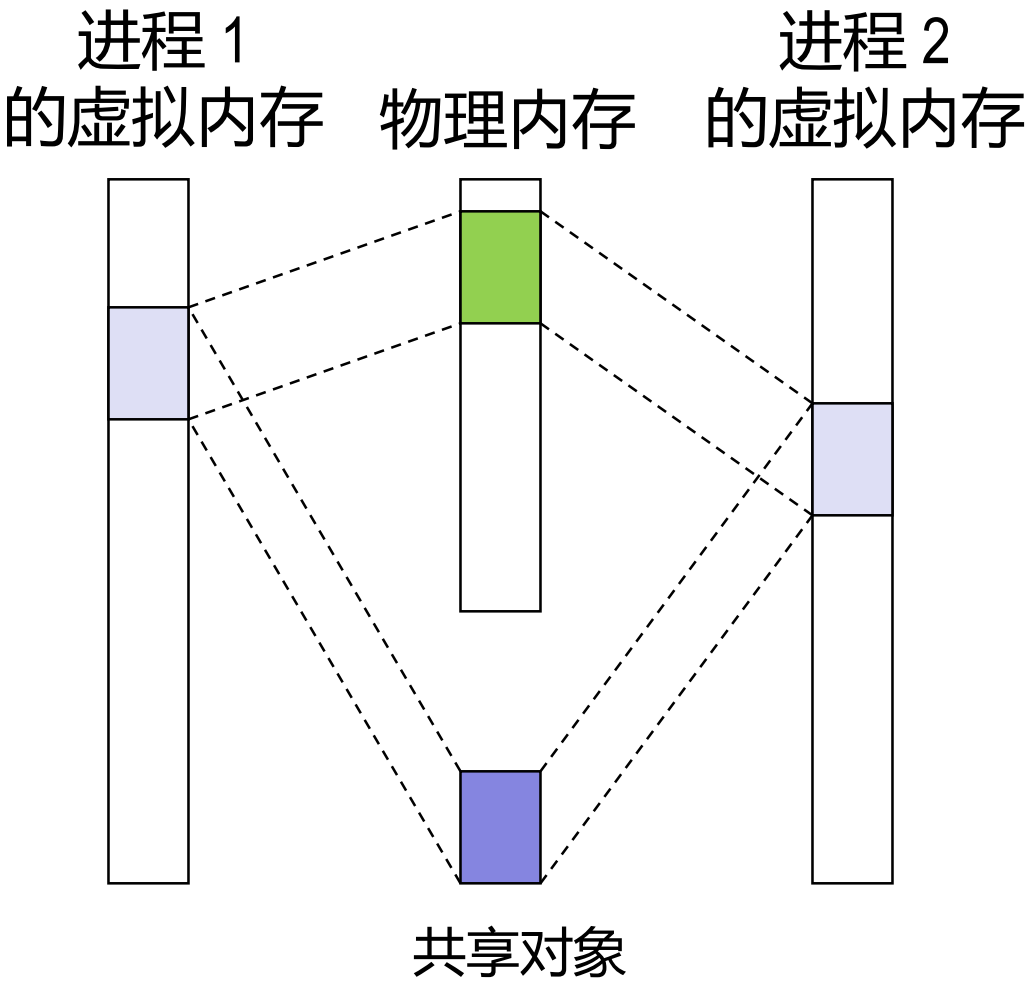

- 进程 2 映射了同一个共享对象。
- 两个进程的虚拟地址可以是不同的。

共享对象: 私有的写时复制对象

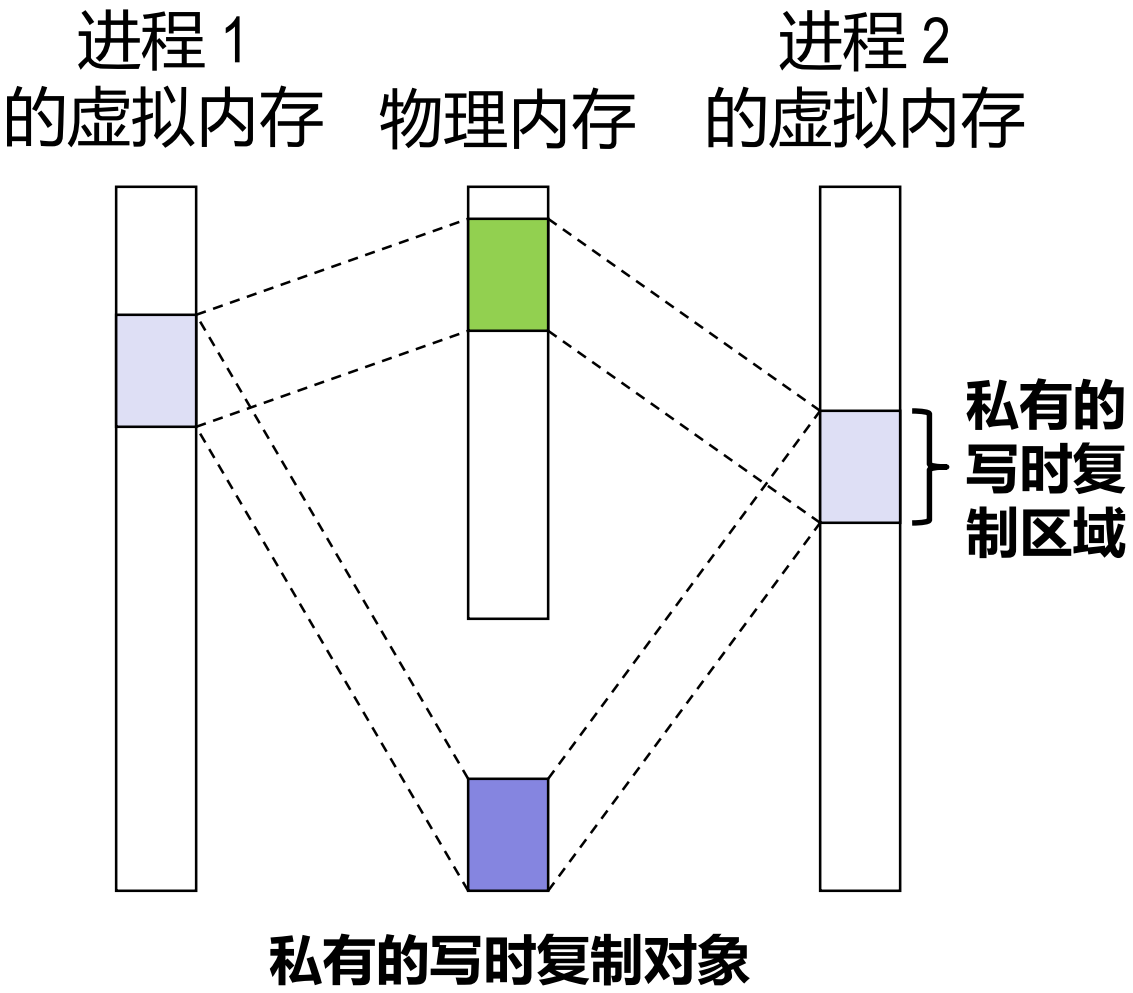

- 两个进程都映射了私有的写时复制对象
- 区域结构被标记为私有的写时复制
- 私有区域的页表条目都被标记为只读

共享对象: 私有的写时复制对象

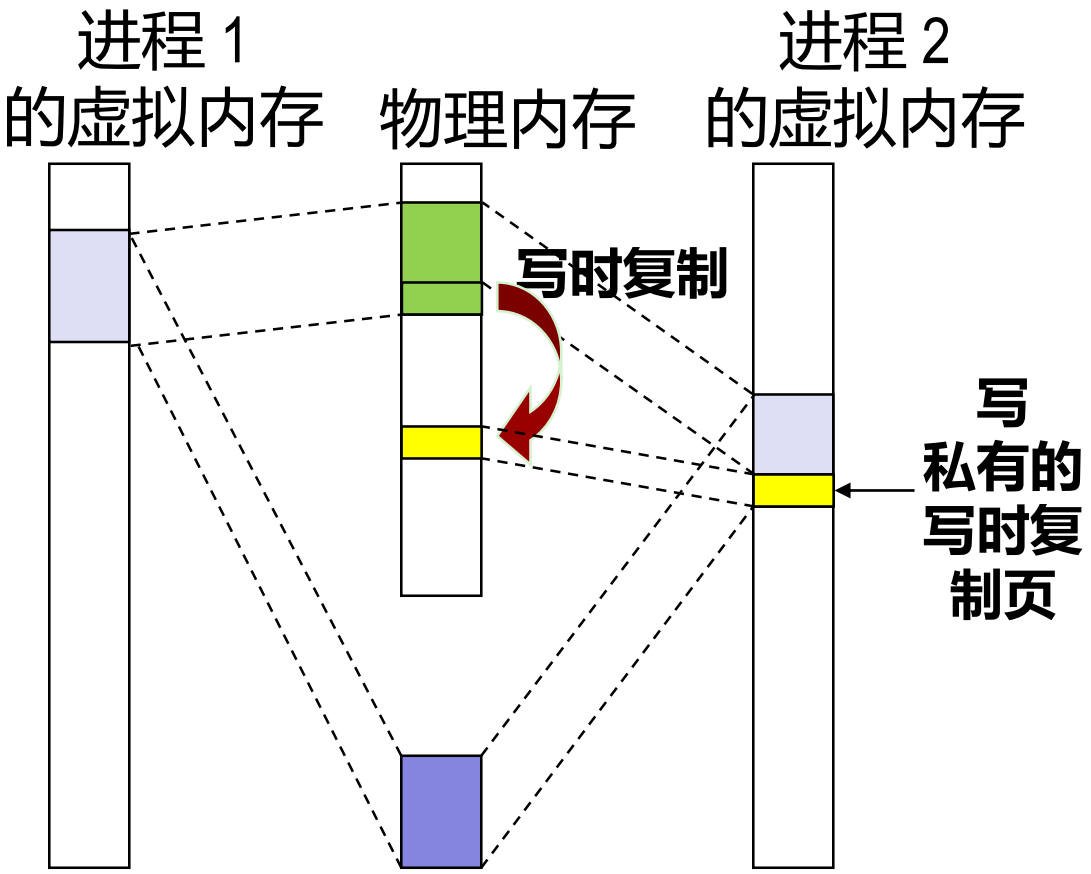

私有的写时复制对象

- 写私有页的指令触发保护故障
- 故障处理程序创建这个页面的一个新副本
- 故障处理程序返回时重新执行写指令
- 能尽可能地延迟拷贝（创建副本）

再看 fork 函数

- 虚拟内存和内存映射解释fork函数如何为每个新进程提供私有的虚拟地址空间。
  - 为新进程创建虚拟内存
    - 创建当前进程的**mm_struct**、**vm_area_struct**和页表的原样副本。
    - 两个进程中的每个页面都标记为只读
    - 两个进程中的每个区域结构(**vm_area_struct**) 都标记为私有的写时复制 (**COW**)
  - 在新进程中返回时，新进程拥有与调用fork的父进程相同的虚拟内存
  - 随后的写操作通过写时复制机制创建新页面

再看 execve 函数

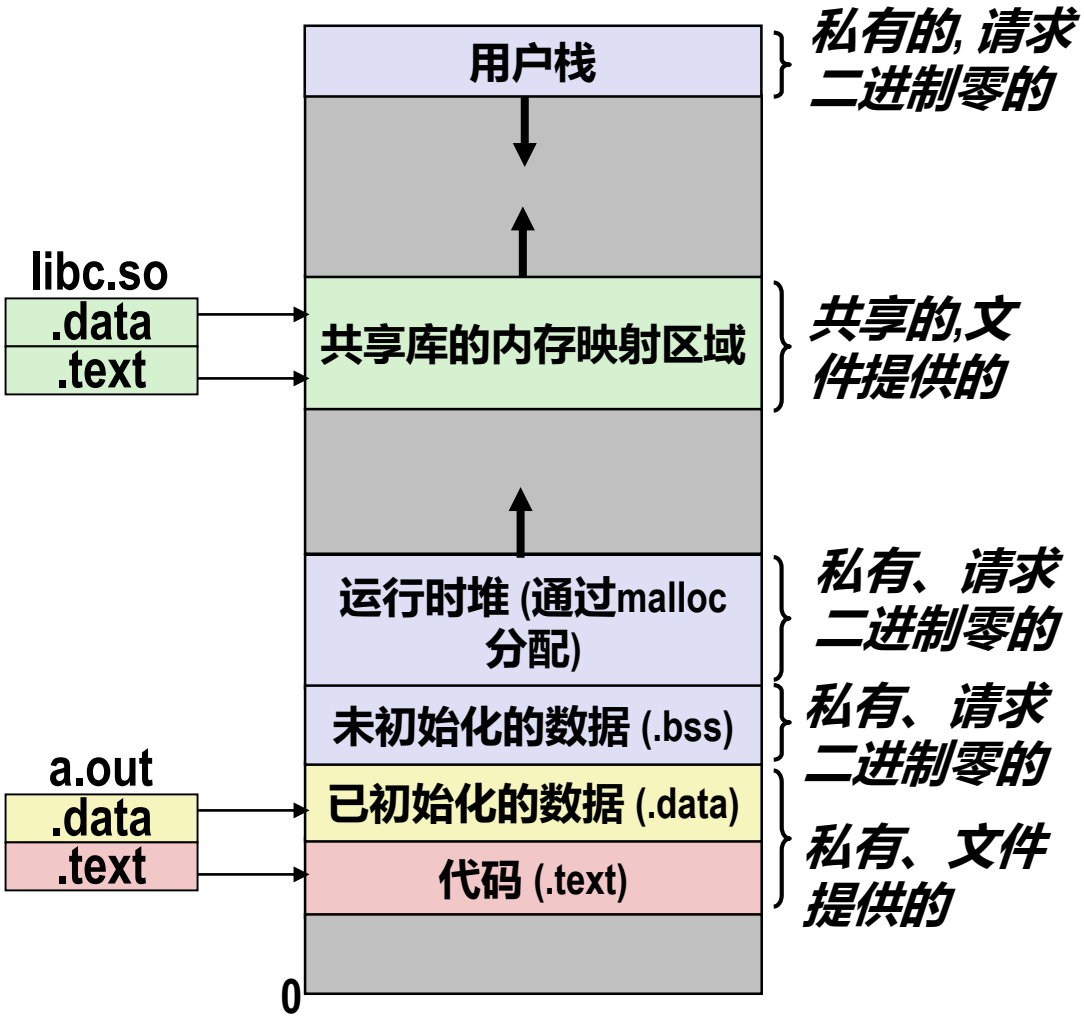

execve函数在当前进程中加载并运行新程序a.out的步骤:

- 删除已存在的用户区域
- 创建新的区域结构
  - 代码和初始化的数据映射到.text和.data区（目标文件提供）
  - .bss和栈映射到匿名文件
- 设置PC，指向代码区域的入口点
  - Linux根据需要换入代码和数据页面

用户级内存映射

void *mmap(void *start, int len, int prot, int flags,
int fd, int offset)

- 从fd指定磁盘文件的offset处，映射len个字节到一个新创建的虚拟内存区域，该区域从地址start处开始
  - **start**：虚拟内存的起始地址，通常定义为NULL
  - **prot**: 虚拟内存区域的访问权限，PROT_READ(可读），PROT_WRITE(可写), PROT_EXEC(可执行），PROT_NONE (不能被访问)
  - **flags**: 被映射对象的类型，MAP_ANON（匿名对象），MAP_PRIVATE（私有的写时复制对象）, MAP_SHARED（共享对象）, ...
- 返回值：指向映射区域开始处的指针

用户级内存映射

void *mmap(void *start, int len, int prot, int flags, int fd, int offset)

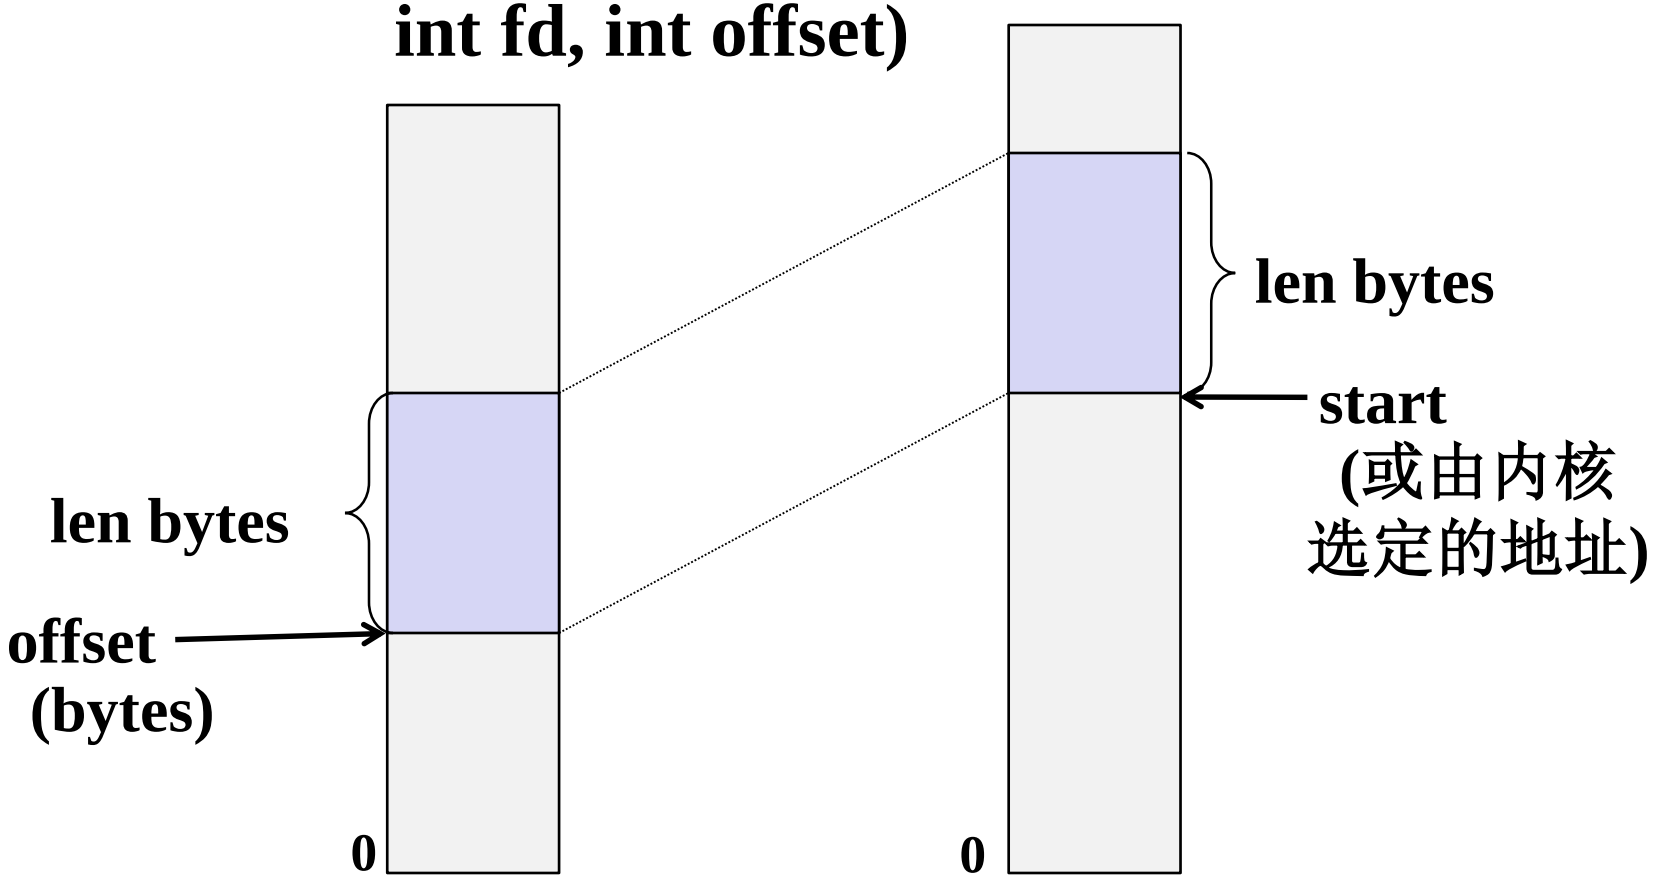

Example: 使用 mmap 函数拷贝文件

- 拷贝一个文件到 stdout (数据没有传输到用户空间)

```
#include "csapp.h"

void mmapcopy(int fd, int size)
{

 /* Ptr to memory mapped area */
   char *bufp;

   bufp = Mmap(NULL, size,
               PROT_READ,
               MAP_PRIVATE,
               fd, 0);
   Write(1, bufp, size);
   return;
}
```

mmapcopy.c

```
/* mmapcopy driver */
int main(int argc, char **argv){
   struct stat stat;
   int fd;
   /* Check for required cmd line arg */
   if (argc != 2) {
      printf("usage: %s <filename>\n",
            argv[0]);
      exit(0);
   }
   /* Copy input file to stdout */
   fd = Open(argv[1], O_RDONLY, 0);
   Fstat(fd, &stat);
   mmapcopy(fd, stat.st_size);
   exit(0);
}
```

mmapcopy.c